

Sistema de reconocimiento de objetos en imágenes. Caso particular: detección de armas

Norida Manuela Iquinás Volverás

Asesor:
Yesid Ospitia Medina

Universidad Icesi
Santiago de Cali, Colombia
Junio 2026

1. Introducción

La detección automática de objetos mediante técnicas de inteligencia artificial ha adquirido gran relevancia en aplicaciones relacionadas con la seguridad y la videovigilancia. En particular, la identificación temprana de armas en imágenes puede contribuir a mejorar los sistemas de monitoreo y apoyar la toma de decisiones en situaciones de riesgo.

Los avances en aprendizaje profundo y visión por computadora han permitido el desarrollo de modelos capaces de detectar objetos con altos niveles de precisión. Entre ellos, la familia de modelos *YOLO* (*You Only Look Once*) se ha destacado por su eficiencia y capacidad de procesamiento en tiempo real.

En este trabajo se desarrolla un sistema para la detección automática de armas en imágenes utilizando la arquitectura *YOLOv8*. Para ello, se emplea un conjunto de datos compuesto por imágenes de cuchillos y pistolas, sobre el cual se realizan procesos de preparación de datos, entrenamiento y evaluación. Adicionalmente, se estudia el impacto de técnicas de *data augmentation* y se comparan las arquitecturas *YOLOv8n* y *YOLOv8m* con el fin de analizar su desempeño y capacidad de generalización.

2. Planteamiento del problema

La presencia de armas en espacios públicos representa un riesgo significativo para la integridad de las personas y para la seguridad ciudadana, especialmente en contextos urbanos donde hay una alta densidad poblacional; en Colombia, esta problemática es persistente.

A nivel nacional, los homicidios constituyen uno de los principales indicadores de inseguridad. En [1] y [2] se expone que los reportes oficiales determinan que el arma de fuego se mantiene entre los mecanismos más frecuentes en las muertes violentas y en los homicidios del país, lo que evidencia la relación entre la circulación de armas y la violencia letal.

En particular, el Valle del Cauca se ha consolidado como uno de los departamentos más afectados por esta problemática. En [1] se muestra que el departamento ha llegado a concentrar aproximadamente el 17 % de los homicidios del país, posicionándose como una de las regiones con mayor incidencia de violencia letal en Colombia .

Además, estudios de seguridad regional como los presentados en [3], indican que algunas subregiones, como el norte del Valle, presentan tasas de homicidio de hasta 94,11 casos por cada 100.000 habitantes, además de un incremento cercano al 13 % entre 2023 y 2024, lo que evidencia un deterioro en las condiciones de seguridad. Los informes territoriales y de salud pública en el departamento [4] han señalado que la violencia letal y los eventos asociados a armas continúan siendo un problema relevante, incluso en contextos donde se han implementado estrategias de control, como la incautación de armas, la cual ha presentado variaciones en los últimos años.

Aunque los sistemas de videovigilancia se han consolidado como herramientas clave para el monitoreo de espacios públicos y privados, su funcionamiento depende en gran medida de la supervisión humana para identificar situaciones sospechosas o amenazas potenciales, lo cual puede resultar ineficiente.

Por otro lado, los avances en inteligencia artificial y visión por computadora han permitido desarrollar técnicas capaces de analizar automáticamente grandes cantidades de información visual. El uso de aprendizaje profundo (deep learning) ha demostrado un alto desempeño en tareas como la clasificación y detección de objetos en imágenes y videos. Estas tecnologías permiten entrenar modelos capaces de identificar patrones complejos en los datos visuales, lo que facilita la detección automática de objetos específicos dentro de una escena.

Los modelos basados en redes neuronales convolucionales (CNN) han sido ampliamente utilizados en aplicaciones de visión por computadora, debido a su capacidad para extraer características relevantes de las imágenes. En particular, los algoritmos de detección de objetos han evolucionado significativamente en los últimos años, permitiendo localizar y clasificar múltiples objetos dentro de una imagen de manera precisa.

Uno de los algoritmos más destacados en este campo es *YOLO* (You Only Look Once), el cual permite realizar detección de objetos en tiempo real mediante una sola evaluación de la imagen por la red neuronal, lo que lo hace especialmente eficiente para aplicaciones de seguridad y vigilancia. Este modelo ha evolucionado a través de diferentes versiones, mejorando progresivamente su precisión y velocidad.

Actualmente, existen versiones más avanzadas como *YOLOv8*. Estudios han demostrado que este modelo pueden alcanzar altos niveles de precisión en la

identificación de armas en imágenes y videos, lo que evidencia su potencial para mejorar los sistemas de seguridad basados en inteligencia artificial [5].

A pesar de los avances en estas tecnologías, aún existe la necesidad de implementar soluciones basadas en inteligencia artificial que permitan detectar automáticamente la presencia de armas en imágenes o videos provenientes de sistemas de vigilancia. La automatización de este proceso puede contribuir a generar alertas tempranas y apoyar la toma de decisiones en situaciones de riesgo.

Por lo tanto, surge la necesidad de desarrollar un sistema basado en técnicas de aprendizaje profundo que permita detectar armas de manera automática en imágenes, utilizando modelos de detección de objetos como *YOLOv8*, con el fin de mejorar la eficiencia de los sistemas de videovigilancia y contribuir al fortalecimiento de la seguridad en entornos urbanos.

3. Objetivo general

Desarrollar un sistema basado en inteligencia artificial para la detección automática de armas en imágenes, con el fin de mejorar la seguridad en entornos urbanos mediante su integración en sistemas de videovigilancia.

3.1. Objetivos específicos

- Estudiar el modelo *YOLOv8* para entender y analizar imágenes mediante inteligencia artificial.
- Investigar y analizar las soluciones tecnológicas existentes en el campo de la detección de armas mediante deep learning para comprender sus ventajas y limitaciones.
- Desarrollar un modelo de detección de armas utilizando técnicas de aprendizaje profundo.

4. Estado del arte

La detección automática de armas en imágenes mediante técnicas de inteligencia artificial ha cobrado gran relevancia debido a su potencial aplicación

en sistemas de seguridad, además que el desarrollo de modelos basados en aprendizaje profundo han permitido mejorar significativamente la capacidad de identificar objetos peligrosos en imágenes.

Una de las investigaciones más recientes se encuentra el trabajo de Thakur et al. [6], quienes desarrollaron un sistema de detección automática de armas utilizando la arquitectura *YOLOv8*. El objetivo principal de dicho trabajo fue evaluar la capacidad del modelo para identificar armas en imágenes de manera eficiente y en tiempo real.

Para llevar a cabo lo anterior, los autores entrenaron y validaron el sistema utilizando métricas estándar en detección de objetos, como *precision*, *recall*, *F1-score* y *mean Average Precision (mAP)*. Los resultados obtenidos evidenciaron que *YOLOv8* ofrece un equilibrio favorable entre velocidad y precisión.

Por otro lado, Shanthi y Manjula [5] propusieron un enfoque híbrido que combina una red neuronal convolucional denominada FMR-CNN con el modelo *YOLOv8*, con el propósito de mejorar el desempeño de la detección de armas en imágenes complejas. Los autores se enfocaron en escenarios donde existen factores que suelen dificultar el reconocimiento visual, tales como ruido, cambios de iluminación, fondos heterogéneos y oclusiones parciales.

Por su parte, Farhan et al. [7] desarrollaron un sistema basado en *YOLOv8* entrenado con un conjunto de datos superior a 10.000 imágenes de armas. El propósito del estudio fue analizar cómo la disponibilidad de un dataset amplio y correctamente etiquetado impacta el desempeño del modelo. Los autores alcanzaron altos valores de *mAP@0.5*, mostrando que la calidad y cantidad de datos utilizados en el entrenamiento son factores determinantes para mejorar la capacidad de generalización del sistema.

Mientras tanto, Murugan [8] presentó un sistema de vigilancia inteligente basado en inteligencia artificial orientado a la detección de armas en imágenes. El estudio no se centró únicamente en la arquitectura del modelo, sino también en etapas complementarias como el preprocesamiento de datos, la optimización del entrenamiento y la adaptación del sistema a condiciones reales de operación. Los resultados mostraron que el rendimiento del modelo depende no solo de la red neuronal utilizada, sino también de la calidad del flujo completo de procesamiento.

La Tabla 1, muestra que los trabajos mencionados coinciden en que los mode-

los basados en *YOLOv8* presentan resultados prometedores para la detección automática de armas en imágenes; esto respalda la elección de *YOLOv8* como base metodológica del presente proyecto.

Tabla 1: Comparación de trabajos recientes sobre detección de armas en imágenes.

Autor	Año	Método	Tipo de datos	Métricas	Principales aportes
Thakur et al.	2024	YOLOv8	Imágenes	Precision, Recall, mAP	Demuestra la viabilidad de YOLOv8 para detección automática de armas con buen desempeño y respuesta rápida.
Shanthi & Manjula	2025	FMR-CNN + YOLOv8	Imágenes	Accuracy, Precision	Mejora la detección en escenarios complejos con ruido, iluminación variable y oclusiones.
Farhan et al.	2025	YOLOv8	Imágenes (10.000+)	mAP@0.5	Evidencia que datasets amplios y bien etiquetados mejoran la robustez y generalización del modelo.
Murugan	2025	Deep Learning aplicado a vigilancia	Imágenes	Accuracy	Resalta la importancia del pre-procesamiento y la optimización del modelo en entornos reales.

A pesar de los avances reportados en la literatura, continúan existiendo desafíos asociados a la capacidad de generalización de los modelos cuando son evaluados sobre imágenes obtenidas en condiciones distintas a las utilizadas durante el entrenamiento. Factores como variaciones de iluminación, fondos complejos, diferencias en la calidad de las imágenes y diversidad de escenarios continúan afectando el desempeño de los sistemas de detección.

5. Metodología

Este proyecto se desarrollará con base en la metodología *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*), la cual se compone de seis fases: comprensión del problema, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue.

5.1. Comprensión del problema

En este momento se identifica la necesidad de contar con herramientas tecnológicas que permitan apoyar los sistemas de videovigilancia en la detección oportuna de armas en imágenes.

5.2. Comprensión de los datos

En esta fase se analizará el conjunto de datos que será utilizado en el proyecto. Para ello, se empleará el dataset “*Detección de armas – Open Data*” publicado por *DaSCI*, el cual contiene imágenes etiquetadas para tareas de detección de armas.

5.3. Preparación de los datos

En esta instancia se incluye la organización del dataset al formato requerido por *YOLOv8*. Posteriormente, el conjunto de datos será dividido en subconjuntos de entrenamiento, validación y prueba, con el propósito de garantizar una evaluación adecuada del modelo.

5.4. Modelado

En esta fase se llevará a cabo el entrenamiento del modelo de detección de armas utilizando *Python* y la librería *YOLOv8*. Se seleccionará una configuración adecuada del modelo y se ejecutará el proceso de aprendizaje a partir de las imágenes y anotaciones del dataset.

5.5. Evaluación

Una vez finalizado el entrenamiento, se evaluará el desempeño del modelo mediante métricas empleadas en tareas de detección de objetos, tales como *precision*, *recall*, *F1-score* y *mAP*. En [6] se muestra que estas métricas permiten analizar la precisión del modelo y su capacidad para detectar correctamente los objetos en una imagen.

5.6. Despliegue

Finalmente, en esta fase se considerará la aplicación del modelo entrenado para la detección de armas en nuevas imágenes, con proyección a su futura integración en sistemas de videovigilancia. Aunque el alcance principal del proyecto se centra en el desarrollo y validación del modelo, esta fase permite establecer el uso potencial del sistema como herramienta de apoyo para la detección temprana de amenazas en contextos de seguridad.

6. Resultados obtenidos

Se desarrollaron las etapas correspondientes a la comprensión de los datos, preparación de los datos, modelado y evaluación experimental utilizando la arquitectura *YOLOv8*. Inicialmente se trabajó con una única categoría de arma (cuchillo); luego, para extender el sistema a un problema multiclase, se introduce la categoría pistola.

6.1. Información y descripción del dataset

Como ya se ha mencionado, para el desarrollo del proyecto se utilizó el conjunto de datos “Detección de armas – Open Data” de DaSCI, el cual contiene imágenes anotadas para tareas de detección de objetos mediante cuadros delimitadores (bounding boxes).

Inicialmente se empleó la subcategoría *Knife Detection*, conformada por imágenes que contienen cuchillos en diferentes escenarios. Posteriormente se incorporó la categoría *Pistol*, permitiendo así construir un dataset multiclase para detectar simultáneamente cuchillos y pistolas.

Las anotaciones originales se encontraban en formato Pascal VOC (XML), por lo que fue necesario convertirlas al formato requerido por *YOLOv8*.

6.2. Análisis exploratorio de los datos

Se realizó un análisis exploratorio del conjunto de datos de donde se pudo identificar:

- Aproximadamente 1948 imágenes válidas para la categoría Knife.
- Aproximadamente 2155 instancias anotadas.
- Presencia de imágenes con múltiples objetos.
- Variabilidad en iluminación, orientación, tamaño y fondo de los objetos.
- Diferencias significativas en la resolución y calidad de las imágenes.

Estas características representan un desafío para el modelo, pero favorecen su capacidad de generalización.

6.3. Preparación y transformación de los datos

Para adaptar el conjunto de datos a *YOLOv8* se realizaron las siguientes actividades:

- Conversión de anotaciones desde Pascal VOC a formato *YOLO*.
- Normalización de coordenadas entre 0 y 1.
- Eliminación de anotaciones sin imagen asociada.
- División de los datos en entrenamiento (80 %) y validación (20 %).
- Organización de carpetas compatibles con *YOLOv8*.
- Creación y configuración del archivo `data.yaml`.

Así, la estructura final utilizada fue:

```
images/train  
images/val  
labels/train  
labels/val
```

6.4. Entrenamiento del modelo de una clase

La primera fase experimental se desarrolló utilizando únicamente la categoría *knife*. Adicionalmente, se utilizó la arquitectura *YOLOv8n* con las siguientes configuraciones:

- Resolución de entrada: 640 píxeles.
- 50 épocas de entrenamiento.
- Entrenamiento sobre GPU en Google Colab.

Los resultados obtenidos fueron:

Métrica	Valor
Precision	0.93
Recall	0.92
mAP@50	0.96
mAP@50-95	0.66

Tabla 2: Resultados del modelo de una clase para detección de cuchillos.

La tabla anterior muestra una alta capacidad del modelo para detectar cuchillos dentro del conjunto de validación.

6.4.1. Evaluación del modelo de una clase con Data Augmentation

Con el objetivo de mejorar la capacidad de generalización del modelo se incorporaron técnicas de aumento de datos durante el entrenamiento. Las transformaciones utilizadas fueron: Rotación, traslación, escalamiento, volteo horizontal y variaciones de brillo.

Luego, se realizaron pruebas sobre imágenes externas al dataset original. Aunque las métricas internas se mantuvieron competitivas, la mejora observada en la validación externa fue limitada, evidenciando que la generalización continúa siendo uno de los principales desafíos del problema.

6.5. Construcción del modelo multiclase

En una segunda etapa se amplió el sistema para detectar simultáneamente dos categorías *Knife* y *Pistol*, para ello se integraron ambos conjuntos de datos en una única estructura compatible con *YOLOv8* y se definieron las clases:

```
0: knife
1: pistol
```

Esta modificación permitió transformar el problema inicial de detección de una clase en un sistema de detección multiclase.

Se tiene 1948 imágenes en la categoría *knife* y 1000 en la categoría *pistol*, así que el total de la cantidad de imágenes utilizadas es 2498.

6.5.1. Resultados del modelo multiclase

Después del entrenamiento del modelo multiclase se obtuvieron los siguientes resultados:

Métrica	Valor
Precision	0.9415
Recall	0.8898
mAP@50	0.9512
mAP@50-95	0.6931

Tabla 3: Resultados del modelo multiclase.

Los resultados muestran que el modelo logró aprender simultáneamente ambas categorías manteniendo un desempeño elevado.

6.5.2. Resultados del modelo multiclase con Data Augmentation

Posteriormente se entrenó una nueva versión incorporando técnicas de aumento de datos. Los resultados obtenidos fueron:

Métrica	Valor
Precision	0.9246
Recall	0.8763
mAP@50	0.9405
mAP@50-95	0.6578

Tabla 4: Resultados del modelo multiclase con data augmentation.

Se puede ver una ligera disminución en las métricas internas respecto al modelo multiclase original, situación que resulta común cuando el modelo se expone a una mayor diversidad de ejemplos durante el entrenamiento.

6.6. Validación externa con imágenes no vistas

Con el propósito de evaluar la capacidad de generalización del sistema, se construyó un conjunto externo denominado DatasetVal2, compuesto por imágenes obtenidas de fuentes diferentes al dataset de entrenamiento.

Se evaluaron diez imágenes que contenían cuchillos o pistolas. Los resultados mostraron:

- El modelo multiclase sin augmentation logró detectar correctamente 4 de las 10 imágenes evaluadas.

- El modelo multiclase con augmentation logró detectar correctamente 2 de las 10 imágenes evaluadas.

En consecuencia, para el conjunto de validación externa utilizado, el modelo multiclase sin augmentation presentó una mejor capacidad de generalización. Aunque las técnicas de aumento de datos incrementaron la diversidad visual durante el entrenamiento, no produjeron una mejora en el desempeño frente a imágenes completamente nuevas.

6.7. Evaluación de una arquitectura más robusta: YOLOv8m

Con el objetivo de analizar el impacto de una arquitectura de mayor capacidad, se entrenó un modelo *YOLOv8m* utilizando el mismo conjunto de datos multiclase.

Los resultados obtenidos fueron:

Métrica	Valor
Precision	0.9440
Recall	0.8860
mAP@50	0.9470
mAP@50-95	0.6990

Tabla 5: Resultados obtenidos con *YOLOv8m*.

Las métricas obtenidas muestran un comportamiento muy similar al alcanzado por *YOLOv8n*. Se observa una ligera mejora en la métrica mAP@50-95, lo que indica una localización más precisa de los objetos detectados.

6.8. Ejemplos de detecciones realizadas en la validación externa

Con el fin de ilustrar el comportamiento de los modelos evaluados, se presentan algunos ejemplos de detecciones realizadas sobre imágenes pertenecientes al conjunto DatasetVal2. Estas imágenes fueron obtenidas de fuentes diferentes al conjunto de entrenamiento y permiten analizar la capacidad de generalización de los modelos frente a escenarios nuevos. Los ejemplos seleccionados

corresponden a detecciones correctas obtenidas por las distintas configuraciones evaluadas, incluyendo *YOLOv8n* multiclase, *YOLOv8n* multiclase con *data augmentation* y *YOLOv8m* multiclase.



Figura 1: Detección correcta de un cuchillo utilizando el modelo *YOLOv8n* multiclase.

La Figura 1 muestra una detección correcta de la categoría *knife* realizada por el modelo *YOLOv8n* multiclase sobre una imagen externa. Este resultado evidencia la capacidad del modelo para identificar objetos de interés en escenarios no observados durante el entrenamiento.



Figura 2: Detección correcta de una pistola utilizando el modelo *YOLOv8n* multiclase con *data augmentation*.

La Figura 2 presenta una detección correcta de la categoría *pistol* realizada por el modelo entrenado con técnicas de aumento de datos. Aunque esta configuración no obtuvo los mejores resultados en la validación externa, la imagen demuestra que el modelo conserva la capacidad de identificar correctamente objetos pertenecientes a las clases estudiadas.



Figura 3: Detección correcta de un cuchillo utilizando el modelo *YOLOv8m* multiclase.

La Figura 3 muestra un ejemplo de detección realizada por el modelo *YOLOv8m*. A pesar de utilizar una arquitectura de mayor capacidad, los resultados obtenidos fueron similares a los alcanzados por *YOLOv8n*, lo que sugiere que el incremento en la complejidad del modelo no produjo mejoras significativas para el conjunto de datos utilizado.

6.9. Discusión de resultados

Los experimentos realizados permitieron comparar diferentes configuraciones del sistema.

Se observó que:

- El modelo *YOLOv8n* multiclase obtuvo el mejor desempeño durante la validación externa.
- Las configuraciones de data augmentation evaluadas no lograron mejorar la capacidad de generalización del sistema.
- *YOLOv8m* obtuvo una ligera mejora en la métrica mAP@50-95, pero no superó a *YOLOv8n* en la validación realizada con imágenes externas.

- Los resultados obtenidos indican que el incremento en la complejidad de la arquitectura no se tradujo en una mejora significativa del desempeño para el problema estudiado.

Estos resultados sugieren que las métricas internas no siempre reflejan completamente el comportamiento del modelo frente a datos reales no vistos.

La Tabla 6 presenta una comparación de las métricas obtenidas por los modelos evaluados; aunque *YOLOv8m* obtuvo una ligera mejora en la métrica mAP@50-95, el modelo *YOLOv8n* multiclase mostró un desempeño más consistente al considerar conjuntamente las métricas internas y la validación externa.

Modelo	Precision	Recall	mAP@50	mAP@50-95
Knife	0.93	0.92	0.96	0.66
Knife + Augmentation	0.93	0.93	0.97	0.73
Multiclase (YOLOv8n)	0.94	0.89	0.95	0.69
Multiclase + Augmentation	0.92	0.88	0.94	0.66
Multiclase (YOLOv8m)	0.94	0.89	0.95	0.70

Tabla 6: Comparación de los modelos desarrollados.

En particular, *YOLOv8n* logró detectar correctamente un mayor número de imágenes no vistas (ver Tabla7), el modelo *YOLOv8n* multiclase obtuvo la mejor capacidad de generalización al detectar correctamente 4 de las 10 imágenes externas evaluadas, evidenciando una mejor capacidad de generalización.

Por lo tanto, el modelo *YOLOv8n* multiclase se considera la configuración más adecuada para el problema abordado en este trabajo.

Modelo	Detecciones correctas	Total imágenes
YOLOv8n Multiclase	4	10
YOLOv8n Multiclase + Augmentation	2	10
YOLOv8m Multiclase	3	10

Tabla 7: Resultados de validación externa sobre DatasetVal2.

Con el fin de garantizar la reproducibilidad de los experimentos y resulta-

dos presentados en este trabajo, el código fuente desarrollado se encuentra disponible públicamente en el siguiente repositorio:

<https://github.com/NoridaM/TrabajoGrado1.git>

7. Aportes

A partir del estado del arte, se identificó que uno de los principales desafíos en los sistemas de detección de armas corresponde a la capacidad de generalización frente a imágenes obtenidas en condiciones diferentes a las utilizadas durante el entrenamiento. En este contexto, los principales aportes de este trabajo son los siguientes:

- Desarrollo de un sistema de detección automática de armas basado en la arquitectura *YOLOv8*, capaz de identificar las categorías *knife* y *pistol* en imágenes digitales.
- Construcción y evaluación de un modelo multiclase que permite detectar simultáneamente diferentes tipos de armas, ampliando el alcance del problema inicialmente abordado mediante un modelo de una clase.
- Evaluación experimental de dos variantes de la familia *YOLO* (*YOLOv8n* y *YOLOv8m*), analizando el efecto del incremento en la complejidad de la arquitectura sobre el desempeño y la capacidad de generalización del sistema.
- Incorporación de una validación externa mediante imágenes obtenidas de fuentes diferentes al conjunto de entrenamiento, proporcionando una evaluación más cercana a escenarios reales y complementando las métricas tradicionales de validación.
- Evidencia experimental de que mayores niveles de complejidad arquitectónica o la aplicación de técnicas de aumento de datos no garantizan necesariamente una mejora en la capacidad de generalización del sistema, resultado que aporta información útil para futuros desarrollos en detección automática de armas.

8. Conclusiones

Hasta la fecha se ha desarrollado un sistema funcional de detección automática de armas utilizando *YOLOv8n*.

Los resultados obtenidos permiten concluir que:

- Las técnicas de data augmentation evaluadas no produjeron mejoras en la validación externa respecto al modelo multiclase base.
- *YOLOv8m* alcanzó métricas internas similares a *YOLOv8n*, aunque no logró superar su desempeño en imágenes externas.
- La capacidad de generalización continúa siendo uno de los principales retos del sistema.

9. Trabajo a futuro

Como trabajo futuro, se plantea ampliar el sistema desarrollado mediante la incorporación de nuevas categorías de armas, tales como rifles, escopetas y otras armas blancas, con el fin de construir un modelo más robusto y representativo de escenarios reales. También, se propone aumentar el tamaño y la diversidad del conjunto de datos, incluyendo imágenes capturadas en diferentes condiciones de iluminación, distancia, ángulo de observación y nivel de oclusión, lo que permitiría mejorar la capacidad de generalización del modelo.

Adicionalmente, sería conveniente evaluar otras configuraciones de aumento de datos (*data augmentation*) y realizar experimentos con arquitecturas más avanzadas de la familia *YOLO*, con el propósito de analizar posibles mejoras en precisión y robustez.

Finalmente, se propone realizar evaluaciones utilizando conjuntos de datos externos de mayor tamaño y diversidad, con el fin de obtener una medición más representativa de la capacidad de generalización del modelo frente a escenarios reales.

Referencias

- [1] Universidad Externado de Colombia. Análisis de la violencia y criminalidad en colombia 2024, 2024. Consultado el 19 de marzo de 2026.
- [2] Instituto Nacional de Medicina Legal y Ciencias Forenses. Forensis 2024. Technical report, Instituto Nacional de Medicina Legal y Ciencias Forenses, 2025. Consultado el 19 de marzo de 2026.
- [3] ProPacífico. Panorama de la seguridad regional 2024. Technical report, ProPacífico, 2025. Consultado el 19 de marzo de 2026.
- [4] Gobernación del Valle del Cauca. Análisis de situación de salud participativo 2024. Technical report, Gobernación del Valle del Cauca, 2024. Consultado el 19 de marzo de 2026.
- [5] P Shanthi and V Manjula. Weapon detection with fmrcnn and yolov8 for enhanced crime prevention and security. *Sci. Rep.*, 15:26766, 2025.
- [6] Ayush Thakur, Akshat Shrivastav, Rohan Sharma, Triyank Kumar, and Kabir Puri. Real-time weapon detection using yolov8 for enhanced safety. *arXiv preprint arXiv:2410.19862*, 2024.
- [7] Alysha Farhan, Muhammad Aftab Shafi, Marwa Gul, Sara Fayyaz, Kifayat Ullah Bangash, Bilal Ur Rehman, Humayun Shahid, and Muhammad Kashif. Deep learning-based weapon detection using yolov8. *International Journal of Innovations in Science & Technology*, 7(2):1269–1280, 2025.
- [8] T. Murugan. Ai-based weapon detection for security surveillance. *Electronics*, 14(23):4609, 2025.